APRENDIZADO PROFUNDO · TRABALHO PRÁTICO

MLP no CIFAR-10

Efeito do dropout e do early stopping na generalização de uma rede totalmente conectada

Arthur Alencar e Vinicius Levi

OBJETIVO

Dropout e early stopping ajudam a MLP a generalizar?

Config.	Dropout	Early stopping
A	Não	Não
B	Não	Sim
C	Sim	Não
D	Sim	Sim

4 × 3

Quatro configurações, cada uma treinada 3 vezes (seeds 0, 1 e 2): **12 treinos**.

Métricas: acurácia de treino e de teste, épocas e tempo.

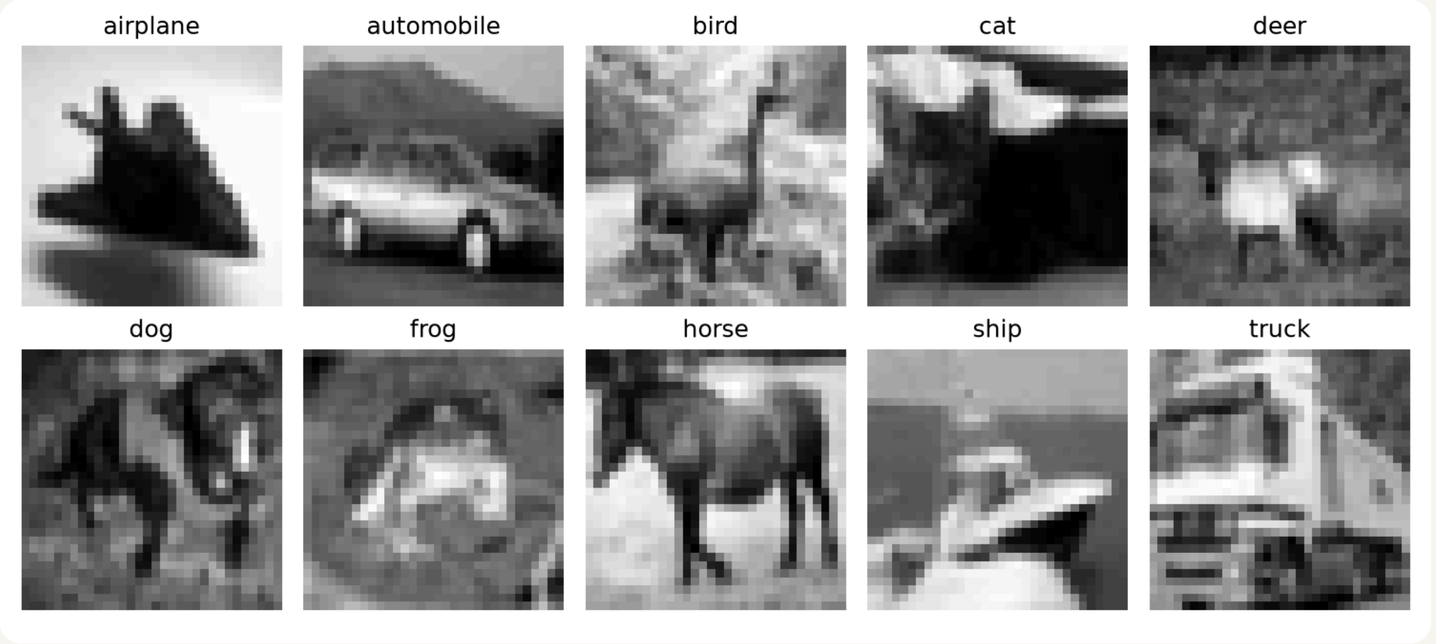
MÉTODO · DADOS

CIFAR-10 em escala de cinza

60 mil imagens 32×32, 10 classes: 50 mil para treino e 10 mil para teste.

RGB → cinza, conforme o enunciado: Y = 0,299 R + 0,587 G + 0,114 B

Achatamento em vetores de 1024 valores, normalizados para [0, 1].



MÉTODO · REFERÊNCIA

A MLP do dropout no MNIST: arquitetura de 2014, treino de 2012

“Dropout: A Simple Way to Prevent Neural Networks from Overfitting”

Srivastava et al., *JMLR*, 2014. Arquitetura e dropout.

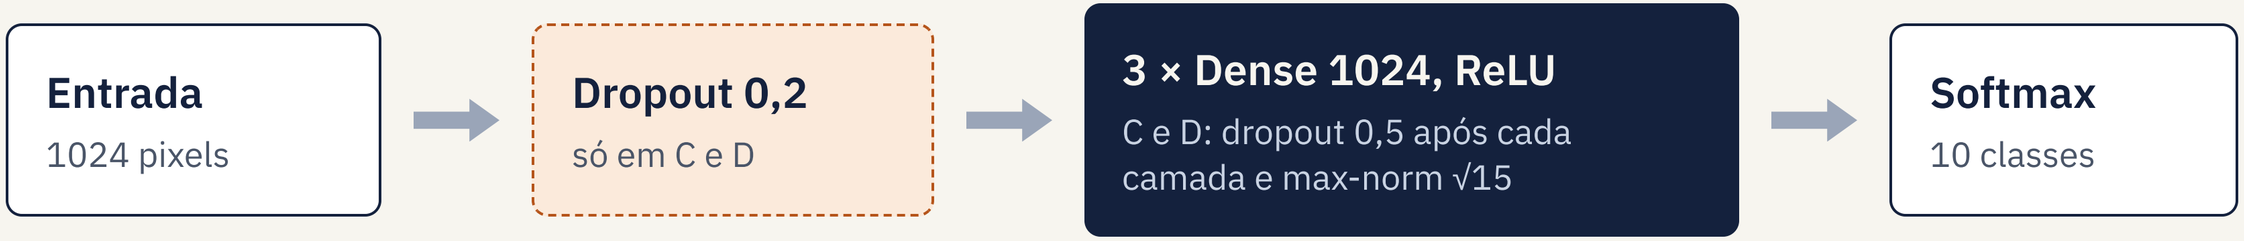
“Improving neural networks by preventing co-adaptation of feature detectors”

Hinton et al., *arXiv*, 2012. Receita de treino.

Item	Origem
3 × 1024, ReLU	Srivastava (Tabela 2)
Dropout 0,2 / 0,5	Srivastava (B.1)
Batch 100	Hinton (A.1)
500 épocas	Hinton (C, Reuters)
Momentum 0,5 → 0,99	Hinton (A.1)
lr × 0,998 por época	Hinton (A.1)
Max-norm √15 · pesos N(0; 0,01)	Hinton (A.1)
lr inicial 0,1 (artigo: 10)	Adaptação nossa

MÉTODO · ARQUITETURA

MLP com 3 camadas ocultas de 1024 neurônios



3,16 M
parâmetros treináveis

A max-norm limita a norma dos pesos que chegam a cada neurônio. O artigo a recomenda junto com o dropout, para permitir taxas de aprendizado maiores sem os pesos explodirem.

MÉTODO · TREINAMENTO

SGD com a agenda de Hinton e 10% do treino para validação

Item	Valor
Otimizador	SGD + momentum
Momentum	0,5 → 0,99 em 500 épocas
Taxa de aprendizado	0,1, × 0,998 por época
Batch	100
Épocas (máx.)	500 (todas)
Perda	Entropia cruzada
Validação	10% do treino

Early stopping (B e D)

- Monitora a perda de validação
- Paciência de 50 épocas
- Restaura os melhores pesos

O split de validação de 10% é usado nas 4 configurações, para que todas treinem com os mesmos 45 mil exemplos.

MÉTODO · PROTOCOLO

12 treinos, com seeds fixas e resultados salvos

3 seeds

Seeds 0, 1 e 2 fixam a inicialização e o embaralhamento. Relatamos média ± desvio-padrão.

≈ 73 min

Tempo total dos 12 treinos numa GPU de notebook (RTX 4050), com até 500 épocas cada.

2 métricas

Acurácia de treino (45 mil) e de teste (10 mil). Em B e D, com os pesos da melhor época.

RESULTADOS

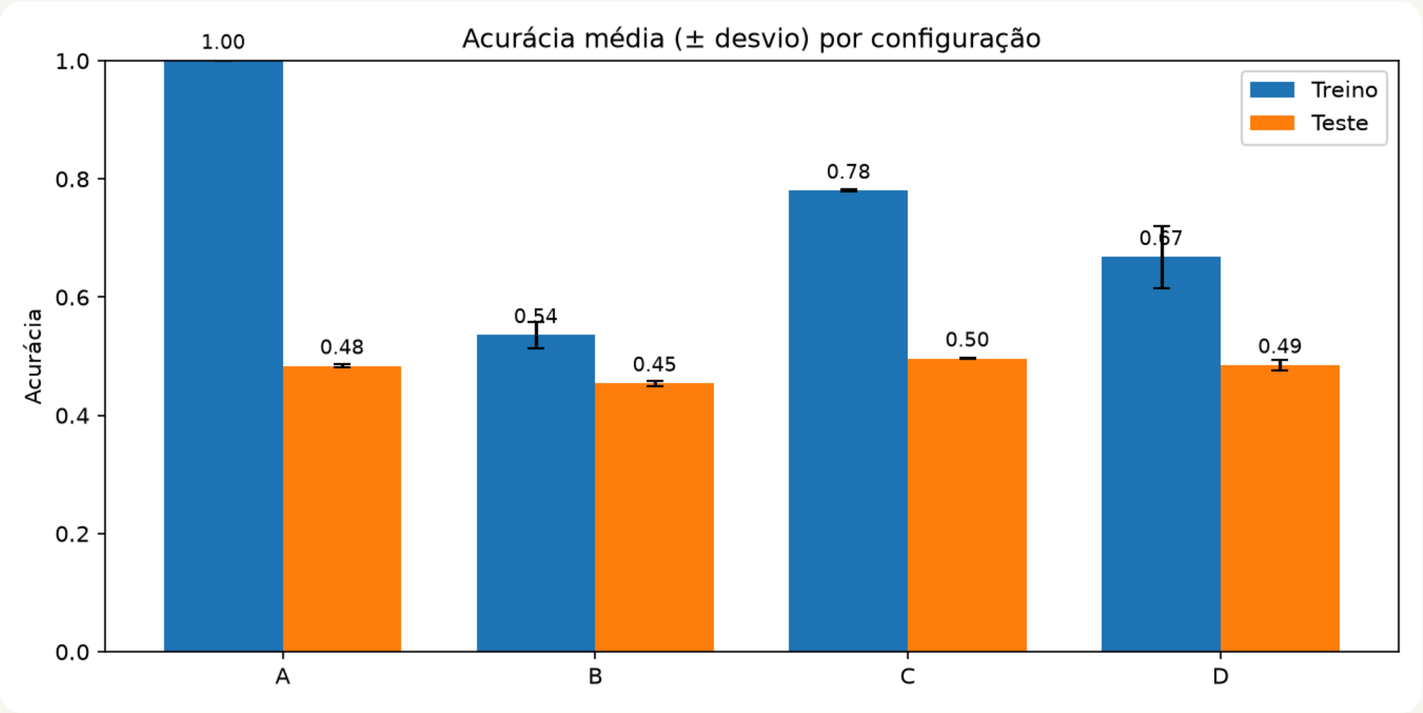
C, só com dropout, tem o melhor teste e o menor desvio

Configuração	Treino (%)	Teste (%)	Gap (p.p.)	Épocas	Tempo
A · nenhuma	100,0 ± 0,0	48,4 ± 0,2	51,6	500	8,4 min
B · early stop	53,6 ± 2,2	45,5 ± 0,4	8,2	73	1,3 min
C · dropout	78,1 ± 0,2	**49,6 ± 0,1**	28,4	500	9,4 min
D · ambos	66,8 ± 5,3	48,5 ± 0,9	18,3	287	5,2 min

Como obtivemos: média ± desvio-padrão das 3 seeds. Treino = acerto nos 45 mil exemplos de treino, com a rede em modo de avaliação (sem dropout); teste = 10 mil imagens nunca vistas. Em B e D, os pesos são os da época de menor perda de validação. Gap = treino – teste. Épocas e tempo: média por execução.

RESULTADOS · TREINO × TESTE

O dropout reduz o gap sem perder teste



A: 100% no treino, 48,4% no teste. Decorou os exemplos.

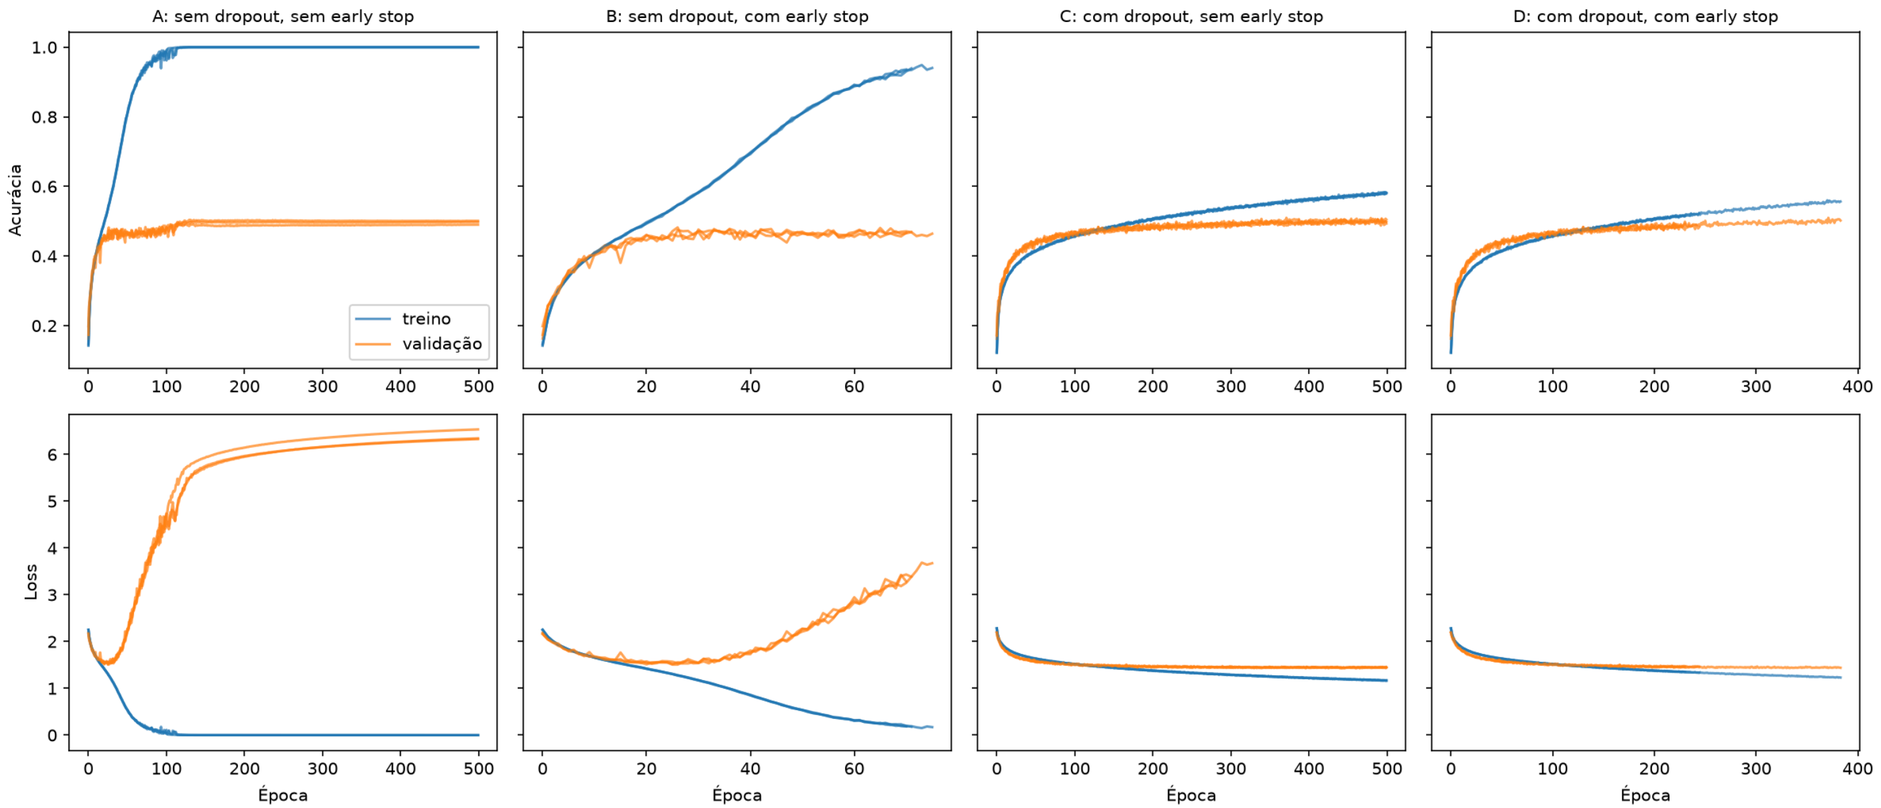
B: menor gap (8,2 p.p.), mas porque parou cedo: treino e teste baixos.

C: gap cai para 28,4 p.p. e o teste sobe. O dropout impede a memorização.

D: parecido com C, com mais variação.

RESULTADOS · CURVAS DE TREINO

Sem dropout, a perda de validação explode; com dropout, fica estável



DISCUSSÃO · EARLY STOPPING

O early stopping economiza tempo, mas parou antes do pico de acurácia

21–26

Época de menor perda de validação em B. A acurácia de validação de A só atinge o pico nas épocas 117–140.

−2,9 p.p.

Teste de B (45,5%) contra A (48,4%), nas 3 seeds.

−43%

Épocas de D em relação a C (287 contra 500), perdendo 1,1 p.p. de teste.

Por quê: o critério monitora a *perda* de validação. Ela mede a confiança da rede e começa a piorar antes da *acurácia*, que ainda melhora por mais ~100 épocas.

DISCUSSÃO · DROPOUT

O dropout foi a única técnica que melhorou o teste

C: só dropout

- Teste de 49,6%, +1,2 p.p. sobre A
- Desvio de 0,1: o mais estável
- Perda de validação estável em ~1,44, contra 6,4 em A

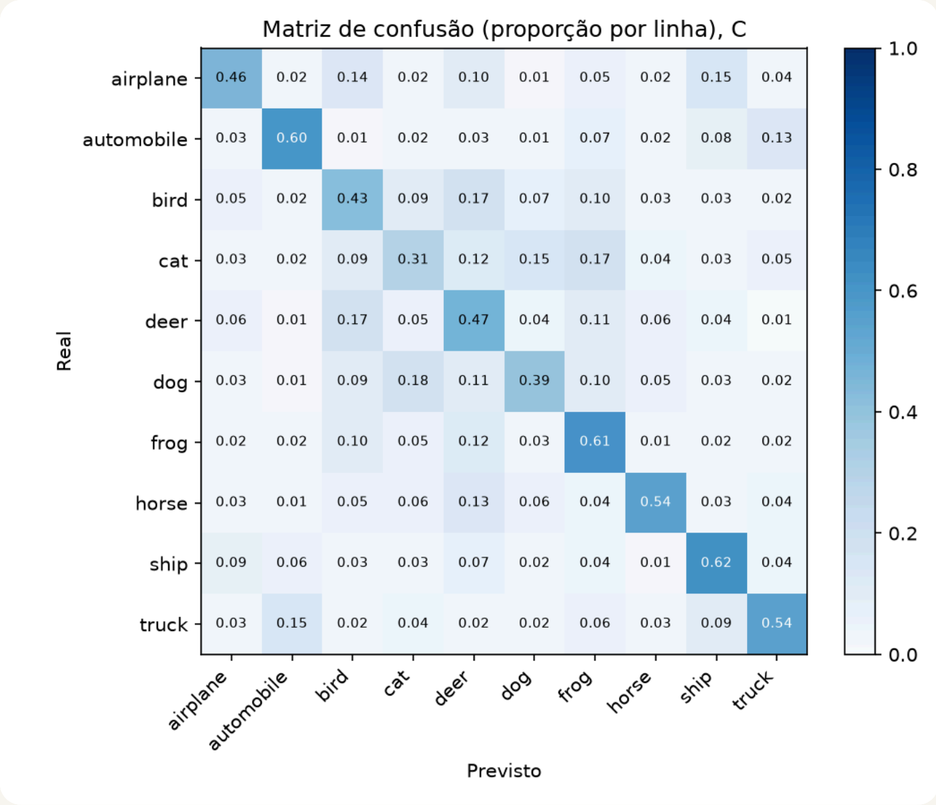
D: dropout + early stop

- Teste de 48,5%, 1,1 p.p. abaixo de C
- Parou entre as épocas 231 e 384
- Maior desvio (0,9): depende de quando para

Por quê: a cada passo, o dropout treina uma sub-rede sorteada. Nenhum neurônio pode contar com outro para decorar um exemplo, então a rede aprende padrões que valem para mais imagens.

RESULTADOS · POR CLASSE

Gato, pássaro e cervo são as classes mais difíceis



Classe (C)	F1
automobile	0,62
horse	0,60
ship	0,59
bird · deer	0,40
cat	0,33
F1-macro	**0,50**

Gato vira sapo (17%) ou cachorro (15%); cachorro vira gato (18%); caminhão vira automóvel (15%).

DISCUSSÃO · LIMITAÇÕES

Por que ~50% e não 90%

MLP ignora o espaço

Achatar a imagem descarta a vizinhança entre pixels. CNNs exploram essa estrutura.

Sem cor

A escala de cinza remove uma pista importante para várias classes.

Receita do MNIST

Só a taxa de aprendizado foi adaptada (0,1 em vez de 10). O resto não foi ajustado para o CIFAR-10.

Só 3 execuções

C × A (1,2 p.p.) e A × B (2,9 p.p.) são claros. C × D (1,1 p.p.) depende do desvio de D (0,9).

CONCLUSÃO

O dropout foi a regularização mais eficaz

Treinamos uma MLP com três camadas ocultas de 1024 neurônios no CIFAR-10 em escala de cinza, usando a arquitetura de Srivastava et al. (2014) e a receita de treino de Hinton et al. (2012), e comparamos quatro configurações, cada uma repetida três vezes. Sem regularização (A), a rede decorou o treino: acertou 100% dos exemplos de treino, mas só 48,4% do teste, e a perda de validação subiu de 1,5 para 6,4. O early stopping sozinho (B) foi o mais rápido, com cerca de 73 épocas, mas teve o pior teste, 45,5%, porque o critério acompanha a perda de validação, cujo mínimo ocorre perto da época 25, antes do pico de acurácia. **O dropout sozinho (C) teve o melhor resultado, 49,6% ± 0,1**, e reduziu a distância entre treino e teste de 51,6 para 28,4 pontos percentuais: ao desligar neurônios ao acaso, impede que a rede memorize exemplos, e a perda de validação se manteve estável. A combinação das duas técnicas (D) chegou a 48,5%, pouco abaixo de C, com 43% menos épocas, mas variou mais entre execuções, porque o momento da parada mudou de uma seed para outra. Concluímos que o dropout foi a regularização mais eficaz e que o early stopping serve mais para economizar tempo do que para ganhar acurácia. O limite próximo de 50% vem do próprio modelo: a MLP ignora a vizinhança entre pixels e a escala de cinza descarta a cor, informações que redes convolucionais aproveitam.

REFERÊNCIAS

Obrigado! Perguntas?

SRIVASTAVA, N.; HINTON, G.; KRIZHEVSKY, A.; SUTSKEVER, I.; SALAKHUTDINOV, R. *Dropout: A Simple Way to Prevent Neural Networks from Overfitting*. Journal of Machine Learning Research, v. 15, n. 56, p. 1929–1958, 2014. jmlr.org/papers/v15/srivastava14a.html

HINTON, G.; SRIVASTAVA, N.; KRIZHEVSKY, A.; SUTSKEVER, I.; SALAKHUTDINOV, R. *Improving neural networks by preventing co-adaptation of feature detectors*. arXiv:1207.0580, 2012. arxiv.org/abs/1207.0580

KRIZHEVSKY, A. *Learning Multiple Layers of Features from Tiny Images*. Relatório técnico, University of Toronto, 2009. (CIFAR-10)

PRECHELT, L. *Early Stopping — But When?* In: Neural Networks: Tricks of the Trade. Springer, 1998.