APRENDIZADO PROFUNDO · TRABALHO PRÁTICO

MLP no CIFAR-10

Efeito do dropout e do early stopping na generalização de uma rede totalmente conectada

Arthur Alencar e Vinicius Levi

OBJETIVO

Dropout e early stopping ajudam a MLP a generalizar?

Config.	Dropout	Early stopping
A	Não	Não
B	Não	Sim
C	Sim	Não
D	Sim	Sim

4 × 3

Quatro configurações, cada uma treinada 3 vezes (seeds 0, 1 e 2): **12 treinos**.

Métricas: acurácia de treino e de teste, épocas e tempo.

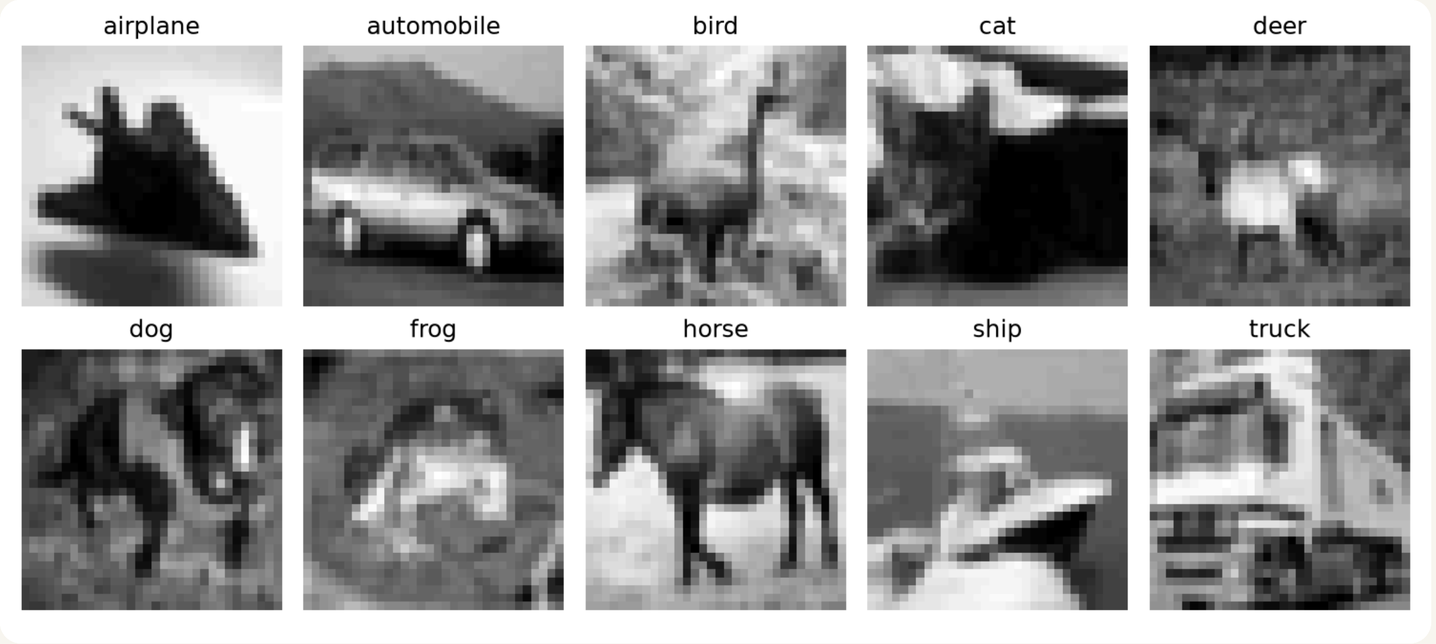
MÉTODO · DADOS

CIFAR-10 em escala de cinza

60 mil imagens 32×32, 10 classes:
50 mil para treino e 10 mil para teste.

RGB → cinza, conforme o enunciado:
Y = 0,299 R + 0,587 G + 0,114 B

Achatamento em vetores de 1024 valores, normalizados para [0, 1].



MÉTODO · REFERÊNCIA

A MLP do artigo que propôs o dropout, usada no MNIST

“Dropout: A Simple Way to Prevent Neural Networks from Overfitting”

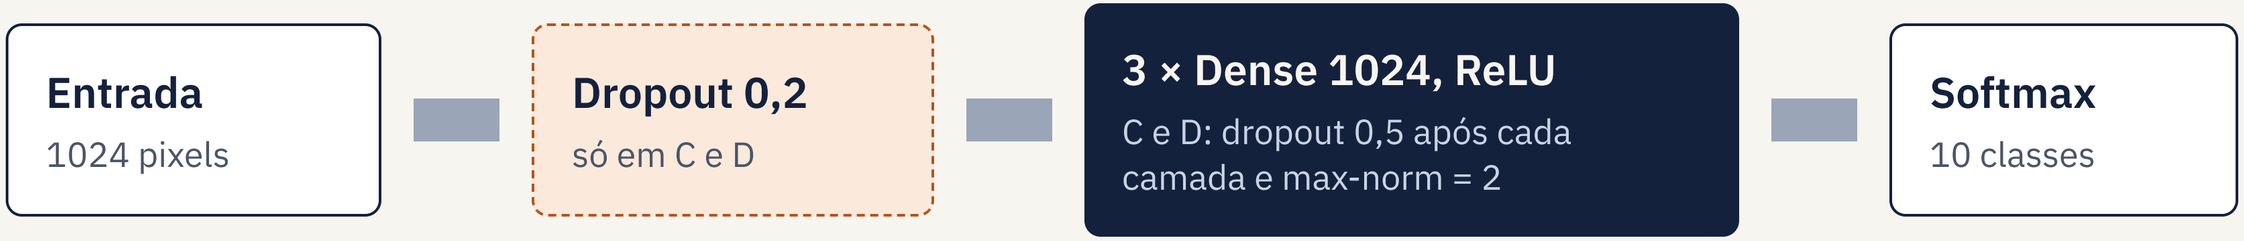
Srivastava et al., *JMLR* 15(56), 2014. Tabela 2 e Apêndices A e B.1.

No MNIST, essa MLP com dropout e max-norm chegou a 1,06% de erro.

Item	Origem
3 × 1024, ReLU	Artigo (Tabela 2)
Dropout 0,2 / 0,5	Artigo (B.1)
Momentum 0,95	Artigo (B.1)
Max-norm c = 2	Artigo (B.1)
lr 0,01 fixo	Nossa escolha
Épocas e batch 100	Nossa escolha; o artigo não informa o batch

MÉTODO · ARQUITETURA

MLP com 3 camadas ocultas de 1024 neurônios



3,16 M
parâmetros treináveis

A max-norm limita a norma dos pesos que chegam a cada neurônio. O artigo a recomenda junto com o dropout, para permitir taxas de aprendizado maiores sem os pesos explodirem.

MÉTODO · TREINAMENTO

SGD com momentum e 10% do treino para validação

Item	Valor
Otimizador	SGD + momentum 0,95
Taxa de aprendizado	0,01
Batch	100
Épocas (máx.)	100 (A, B) · 300 (C, D)
Perda	Entropia cruzada
Validação	10% do treino

Early stopping (B e D)

- Monitora a perda de validação
- Paciência de 10 épocas
- Restaura os melhores pesos

O split de validação de 10% é usado nas 4 configurações, para que todas treinem com os mesmos 45 mil exemplos.

MÉTODO · PROTOCOLO

12 treinos, com seeds fixas e resultados salvos

3 seeds

Seeds 0, 1 e 2 fixam a inicialização e o embaralhamento. Relatamos média ± desvio-padrão.

≈ 30 min

Tempo total de treino numa GPU de notebook (RTX 4050).

2 métricas

Acurácia de treino (45 mil) e de teste (10 mil), medidas com os pesos finais.

RESULTADOS

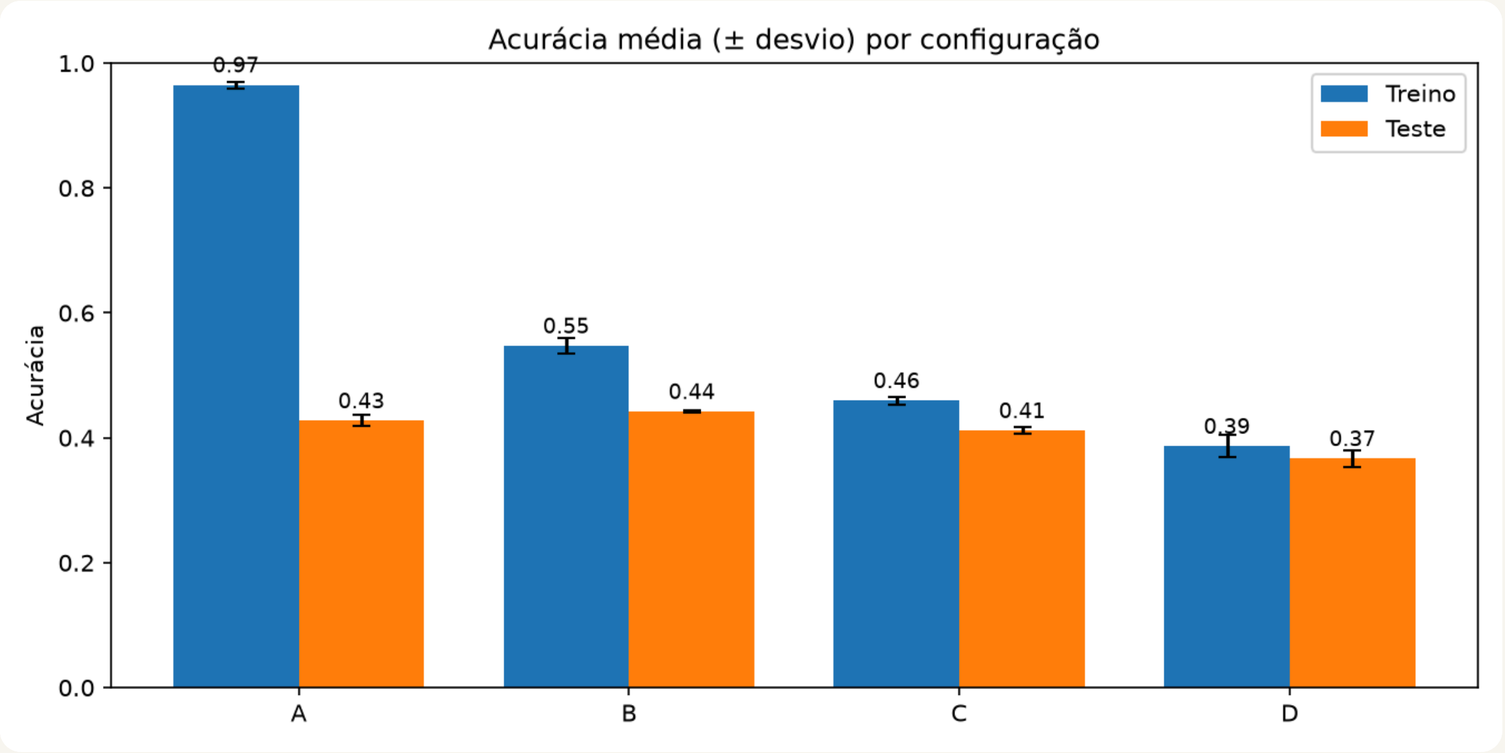
B tem a melhor acurácia de teste, e é a mais rápida

Configuração	Treino (%)	Teste (%)	Gap (p.p.)	Épocas	Tempo
A · nenhuma	96,5 ± 0,5	42,7 ± 0,9	53,8	100	110 s
B · early stop	54,7 ± 1,2	**44,2 ± 0,3**	10,5	24	28 s
C · dropout	46,0 ± 0,6	41,2 ± 0,5	4,8	300	343 s
D · ambos	38,7 ± 1,8	36,7 ± 1,4	2,0	85	101 s

Média ± desvio-padrão de 3 execuções. Treino medido nos 45 mil exemplos de treino. Gap = treino − teste. Épocas e tempo: média por execução.

RESULTADOS · TREINO × TESTE

A regularização fecha a distância entre treino e teste



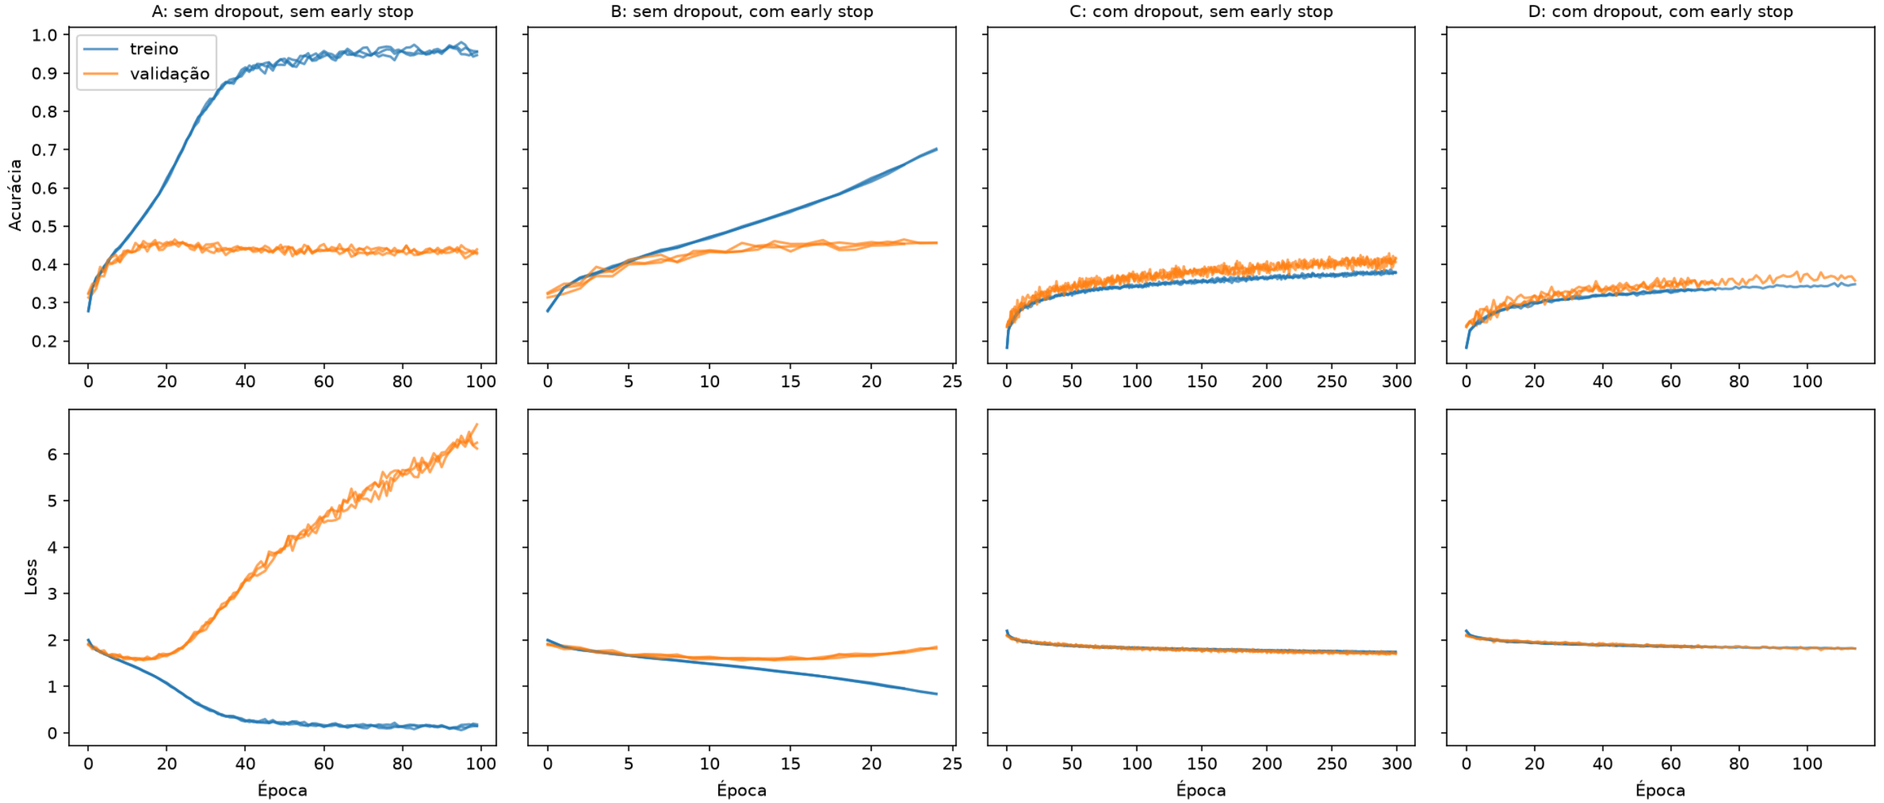
A: decora o treino (96,5%); gap de 53,8 p.p.

B: gap de 10,5 p.p. e o maior teste

C e D: gap abaixo de 5 p.p., mas treino e teste mais baixos

RESULTADOS · CURVAS DE TREINO

Sem regularização, a perda de validação explode depois da época ~15



DISCUSSÃO · EARLY STOPPING

Parar na época ~15 rendeu o melhor teste com 1/4 do tempo

13–15

Época com a menor perda de validação em A e B, nas 3 seeds.

44,2%

Teste de B, contra 42,7% em A. Melhor nas 3 seeds, com desvio de 0,3.

28 s

Tempo médio de B, contra 110 s em A: ~24 épocas em vez de 100.

Em D, porém, o early stopping disparou nas 3 execuções, entre as épocas 67 e 115, cedo demais para uma rede com dropout.

DISCUSSÃO · DROPOUT

O dropout quase eliminou o overfitting, mas aprende devagar

C: só dropout

- Gap de 4,8 p.p., contra 53,8 em A
- Teste de 41,2%, ainda abaixo de B
- Menor perda de validação nas épocas 287–299: ainda aprendendo

D: dropout + early stop

- Pior teste: 36,7%
- Parou nas épocas 67–115 de 300
- Paciência de 10 épocas é curta para a validação lenta e ruidosa

DISCUSSÃO · LIMITAÇÕES

Por que ~40% e não 90%

MLP ignora o espaço

Achatar a imagem descarta a vizinhança entre pixels. CNNs exploram essa estrutura.

Sem cor

A escala de cinza remove uma pista importante para várias classes.

Hiperparâmetros do MNIST

No CIFAR-10, o artigo usa CNN com cor e ZCA; adaptamos a MLP do MNIST sem ajustá-la.

Só 3 execuções

Bastam para B × C (3 p.p.); B × A (1,5 p.p.) é consistente, mas pequeno.

CONCLUSÃO

As duas técnicas combatem o overfitting, mas não se somam

Early stopping escolhe o momento certo de parar: deu a melhor acurácia de teste (44,2%), a mais estável e a mais barata.

Dropout impede a rede de decorar o treino (gap de 4,8 p.p.), mas precisa de muito mais épocas: 41,2% após 300.

Juntas, com paciência de 10 épocas, pioraram (36,7%): o early stopping interrompe a rede com dropout antes de ela convergir.

REFERÊNCIAS

Obrigado! Perguntas?

SRIVASTAVA, N.; HINTON, G.; KRIZHEVSKY, A.; SUTSKEVER, I.; SALAKHUTDINOV, R. *Dropout: A Simple Way to Prevent Neural Networks from Overfitting*. Journal of Machine Learning Research, v. 15, n. 56, p. 1929–1958, 2014. jmlr.org/papers/v15/srivastava14a.html

KRIZHEVSKY, A. *Learning Multiple Layers of Features from Tiny Images*. Relatório técnico, University of Toronto, 2009. (CIFAR-10)

PRECHELT, L. *Early Stopping — But When?* In: Neural Networks: Tricks of the Trade. Springer, 1998.